

# 1 07/07/26

## 1.1 Outline do projeto

- Temas Centrais: O artigo foca em duas frentes: a extensão do modelo de Potts para incorporar efeitos espaciais de centralidade e na solução do problema de verossimilhança intratável através de uma abordagem Bayesiana, necessária para a resolução da primeira.
- Problemas: O modelo de Potts padrão não é capaz de atribuir características a uma determinada região de um grid. A constante de normalização  $Z$  impede o uso de Máxima Verossimilhança tradicional em grids reais.
- Solução Proposta: Adição de uma variável  $\gamma$  referente a atração/repulsão de determinada cor em relação ao centroide. Uso da Pseudoverossimilhança combinada com Metropolis-Hastings para inferir os parâmetros, além de kmeans para descobrir a localização dos centroides.

## 1.2 Esqueleto do artigo

Título: Estimação Bayesiana via Pseudoposteriori em Modelos de Potts com Efeitos de sementes.

### I. Introdução

- Contextualização: Explicar o tipo de dado e como MRF é usado para a análise até agora;
- O Problema da Intratabilidade: Explicação de por que a função de partição  $Z$  não pode ser calculada nos métodos clássicos de estimação;
- A proposta do centroide: Mostrar a necessidade de haver um modelo que trate também de relações entre centroides;
- Objetivo: Propor o modelo reparametrizado, descrever a inclusão de centroides e validar a inferência via Pseudoposteriori.

### II. O Modelo Potts Reparametrizado

- Equação de Energia: Definição do modelo base com parâmetros  $\alpha$  e  $\beta$ ;
- Adição de Efeitos de Centralidade: Introdução do parâmetro  $\gamma$  e a distância normalizada;
- Múltiplos Centroides: Regra do centroide mais próximo;
- Equilíbrio: Discussão sobre o limiar entre penalização global e efeito do centroide.

### III. Métodos de Inferência

- Kmeans;
- Pseudoverossimilhança;
- (TALVEZ) Máxima Verossimilhança via Monte Carlo;;
- Metropolis-Hastings via Pseudoposteriori;

#### IV. (TALVEZ) Implementação Computacional

- Geração de Imagens: Regra de começar com uma imagem aleatória e ir usando o Gibbs Sampler;
- Performance: Truque de tirar o máximo do denominador no cálculo da log-verossimilhança e Repp;

#### V. Resultados e Discussão

- Experimentação: Cenários simulados com diferentes valores de atração/repulsão e localizações de centroides;
- Simulação e convergência: Gráficos de passeio aleatório, densidades, localização dos centroides e etc;
- Replicação: Comparação entre imagens geradas vs inferidas;
- Aplicação: Aplicação em dados reais.

#### VI. Conclusão

- Síntese: Reafirmar que a Pseudoposteriori realmente funciona bem para o problema;
- Vantagens do Modelo: Voltar aos pontos da introdução e aplicação.
- Próximos passos: Discutir possíveis propostas de melhorias ou novas aplicações para o modelo

## 2 13/07/26

### 2.1 Esqueleto do artigo

Título: Estimação Bayesiana via Pseudoposteriori em Modelos de Potts com Efeitos de sementes.

#### I. Introdução

- Contextualização: Explicar o tipo de dado e como MRF é usado para a análise até agora;
- O Problema da Intratabilidade: Explicação de por que a função de partição  $Z$  não pode ser calculada nos métodos clássicos de estimação;
- A proposta do centroide: Mostrar a necessidade de haver um modelo que trate também de relações entre centroides;
- Objetivo: Propor o modelo reparametrizado, descrever a inclusão de centroides e validar a inferência via Pseudoposteriori.

#### II. O Modelo Potts Reparametrizado

- Equação de Energia: Definição do modelo base com parâmetros  $\alpha$  e  $\beta$ ;
- Adição de Efeitos de Centralidade: Introdução do parâmetro  $\gamma$  e a distância normalizada;
- Múltiplos Centroides: Regra do centroide mais próximo;
- Equilíbrio: Discussão sobre o limiar entre penalização global e efeito do centroide.

#### III. Métodos de Inferência

- Kmeans: Introduzir o problema do chute inicial do centroide, a motivação da escolha do Kmeans e como é usado no processo de inferência;
- Pseudoverossimilhança: Explicar sobre o problema da intratabilidade do denominador, como isso é contornado pela pseudoverossimilhança e como se encaixa no algoritmo;
- Metropolis-Hastings via Pseudoposteriori: Mostrar toda a 'pipeline' e como ocorre a atualização em duas etapas, as prioris utilizadas e a regra de aceitação do passo;

#### IV. Resultados e Discussão

- Experimentação: Cenários simulados com diferentes valores de atração/repulsão e localizações de centroides;

- Simulação e convergência: Gráficos de passeio aleatório, densidades, localização dos centroides e etc;
- Replicação: Comparação entre imagens geradas vs inferidas.

#### V. Aplicação Prática

- Introdução: Destacar o problema a ser atacado e possíveis pré-tratamentos anteriores ao uso do modelo;
- Aplicação: Aplicação em dados reais.

#### VI. Conclusão

- Síntese: Reafirmar que a Pseudoposteriori realmente funciona bem para o problema;
- Vantagens do Modelo: Voltar aos pontos da introdução e aplicação.
- Próximos passos: Discutir possíveis propostas de melhorias ou novas aplicações para o modelo

## 2.2 Esboço Cap.2 - The Reparameterized Potts Model

Spatial data modeling on regular lattices often employs Markov Random Fields (MRF) to describe local dependencies. While the Ising model is restricted to binary states, the Potts model extends this framework to multiple categories. In this section, we propose a reparameterized version of the Potts model that incorporates global category abundance but also geographic centrality effects.

### 2.2.1 Energy Formulation and Gibbs Measure

Following the framework of Kindermann and Snell (1980), we consider a set of colors  $S = 0, 1, \dots, r$  assigned to a regular grid  $T$ . To facilitate parameter representation and interpretability, we utilize dummy variables  $s_{i,k} \in \{0, 1\}$ , where  $s_{i,k} = 1$  if pixel  $i$  has color  $k$  and 0 otherwise.

The energy  $U(\omega)$  of a given image configuration  $\omega$  is defined as:

$$U(\omega) = -\alpha \sum_{\{i,j\} \in E} \sum_{k \in S} s_{i,k} s_{j,k} - \sum_{i \in T} \sum_{k \in S} \beta_k s_{i,k} \quad (1)$$

where  $\alpha$  is the uniformity bias (negative values favor same-color neighbors) and  $\beta_k$  is the global penalty for color  $k$ . The probability is given by the Gibbs Measure  $P(\omega) = \frac{1}{Z} e^{U(\omega)}$ .

### 2.3 Incorporation of Geographic Centrality Effects

We introduce a parameter  $\gamma_k$  associated with the normalized Euclidean distance  $d_i$  between pixel  $i$  and a centroid  $c$ . Let  $CB_{k,i}$  be the centrality bias for color  $k$  in the pixel  $i$ :

$$CB_{k,i} = \gamma_k \cdot d_i, \quad \text{with} \quad d_i = \frac{\sqrt{2}(\|i - c\| + 1)}{g} \quad (2)$$

where  $g$  is the grid side. Negative  $\gamma_k$  values penalize color energy far from the center (attraction), while positive values penalize it near the center (repulsion). The augmented energy is:

$$U(\omega) = -\alpha \sum_{\{i,j\} \in E} \sum_{k \in S} s_{i,k} s_{j,k} - \sum_{i \in T} \sum_{k \in S} (\beta_k + \gamma_k d_i) s_{i,k} \quad (3)$$

For identifiability, color 0 is fixed as a reference ( $\beta_0 = 0, \gamma_0 = 0$ ).

### 2.4 Extension to Multiple Centroids

To support  $m$  centroids, each pixel considers only its nearest neighbor:  $d_i = \min(d_{i,1}, \dots, d_{i,m})$ . This effectively partitions the space into regions of influence for each centroid.

### 2.5 Null Region and Influence Area

The null region for a color occurs when  $\beta_k + \gamma_k d_i = 0$ , so everything that happens in this region depends exclusively on  $\alpha$ . This region leads us to the ratio  $d_i = -\beta_k / \gamma_k$ , also known as the influence area of a color-centroid.

### 2.6 21/07/26

### 2.7 Esboço Cap.2 - The Reparameterized Potts Model

Spatial data modeling on regular lattices often employs Markov Random Fields (MRF) to describe local dependencies. While the Ising model is restricted to binary states, the Potts model extends this framework to multiple categories. Models like those mentioned have traditionally relied on the assumption of spatial homogeneity, where the interaction between pixels depends solely on their relative positions and color equality. However, many real-world phenomena exhibit effects such as "seeds" or points of interest that dictate the spatial distribution of categories, at least for a certain region. In this section, we extend the classical Potts model framework to incorporate these geographic influences, which we term "seeds" or "centroids".

### 2.7.1 Energy Formulation and Gibbs Measure

Following the framework of Kindermann and Snell (1980), we consider a random field defined over a squared grid  $T$ , where each pixel  $i \in T$  takes a value from a finite set of colors  $S = 0, 1, \dots, r$ . To facilitate parameter estimation and interpretability, we utilize dummy variables  $s_{i,k} \in \{0, 1\}$ , where  $s_{i,k} = 1$  if pixel  $i$  has color  $k$  and 0 otherwise.

The probability of any given configuration  $\omega$  is governed by the Gibbs Measure:

$$P(\omega) = \frac{1}{Z} e^{U(\omega)} \quad (4)$$

where  $Z = \sum_{\omega \in \Omega} e^{U(\omega)}$  is the partition function, representing the sum over all possible lattice configurations Geyer (1992). The energy function  $U(\omega)$  for our base reparameterized model is defined as:

$$U(\omega) = -\alpha \sum_{\{i,j\} \in E} \sum_{k \in S} s_{i,k} s_{j,k} - \sum_{i \in T} \sum_{k \in S} \beta_k s_{i,k} \quad (5)$$

In this formulation,  $\alpha$  acts as the *uniformity bias* (or smoothing parameter); negative values of  $\alpha$  increase the likelihood of neighboring pixels sharing the same color, thereby favoring the formation of uniform clusters. The parameter  $\beta_k$  serves as a *global penalty* for color  $k$ , controlling its overall abundance throughout the entire lattice.

But as we can see, those two parameters can not handle the "seed" effects. Even though  $\alpha$  could create some clusters, they do not obey a geographical dependency and  $\beta$  treat every pixel as the same at penalizing color abundance. Therefore, we have to bring a new variable or a new set of them.

## 2.8 Incorporation of Geographic Centrality Effects

To address the isotropic limitation of the Potts model, which fails to account for regionalized attraction or repulsion, we introduce a pair of elements to handle the geographic centrality bias ( $\gamma_k$  and  $d_{i,c}$ ) that modifies the local energy of a color based on its distance to a specific point  $c$  in the grid.

This distance is calculated based on the pixel  $i$  related to the centroid  $c$  as

$$d_{i,c} = \frac{\sqrt{2}(\|i - c\| + 1)}{g} \quad (6)$$

where  $g$  is the grid side. While the parameter  $\gamma_k$  quantifies the strength and direction of the seed's influence:

- **Attraction** ( $\gamma_k > 0$ ): Farther distances increase the energy penalty, effectively "pulling" color  $k$  toward the centroid.
- **Repulsion** ( $\gamma_k < 0$ ): Pixels near the centroid are penalized, "pushing" the color toward the lattice boundaries.

The augmented energy function, which allows the model to capture both local neighbor interactions and global geographic trends, is expressed as

$$U(\omega) = -\alpha \sum_{\{i,j\} \in E} \sum_{k \in S} s_{i,k} s_{j,k} - \sum_{i \in T} \sum_{k \in S} (\beta_k + \gamma_k d_i) s_{i,k} \quad (7)$$

For model identifiability, one color (typically color 0) is fixed as a reference with  $\beta_0 = 0$  and  $\gamma_0 = 0$ , ensuring the parameter space is well-defined for estimation.

So now that the centrality effect is addressed, it is time to think about more complex problems where we could have more than one seed and how multiple seeds can affect pixels.

## 2.9 Extension to Multiple Centroids

To model more elaborate images where multiple centers of influence exist, we generalize the distance metric. For a set of  $m$  centroids, each pixel  $i$  is assumed to be geographically influenced only by its nearest neighbor centroid:

$$d_i = \min(d_{i,1}, d_{i,2}, \dots, d_{i,m}) \quad (8)$$

This nearest-neighbor rule effectively partitions the lattice into regions of influence, where the specific  $\gamma_{k,m}$  associated with each seed dictates the local probability distribution of colors.

This limit regions of a centroid influence offer a cool sight of the model interpretation.

## 2.10 Null Region and Influence Area

A critical conceptual contribution of this reparameterization is the definition of the *influence area*. We identify the "null region" for a specific color  $k$  as the set of pixels  $i$  where the global penalty and the centroidal bias cancel each other out:

$$\beta_k + \gamma_k d_i = 0 \Rightarrow d_i = -\frac{\beta_k}{\gamma_k} \quad (9)$$

This ratio establishes a spatial threshold. Within this radius, we have the "influence area"; where the seed's attraction or repulsion dominates the landscape; beyond it, the global abundance parameter  $\beta_k$  becomes the primary driver of the color's presence. To ensure this threshold falls within the grid boundaries, the model generally requires  $|\beta_k| < |\gamma_k|$ .