

1 07/07/26

1.1 Outline do projeto

- Temas Centrais: O artigo foca em duas frentes: a extensão do modelo de Potts para incorporar efeitos espaciais de centralidade e na solução do problema de verossimilhança intratável através de uma abordagem Bayesiana, necessária para a resolução da primeira.
- Problemas: O modelo de Potts padrão não é capaz de atribuir características a uma determinada região de um grid. A constante de normalização Z impede o uso de Máxima Verossimilhança tradicional em grids reais.
- Solução Proposta: Adição de uma variável γ referente a atração/repulsão de determinada cor em relação ao centroide. Uso da Pseudoverossimilhança combinada com Metropolis-Hastings para inferir os parâmetros, além de kmeans para descobrir a localização dos centroides.

1.2 Esqueleto do artigo

Título: Estimação Bayesiana via Pseudoposteriori em Modelos de Potts com Efeitos de sementes.

I. Introdução

- Contextualização: Explicar o tipo de dado e como MRF é usado para a análise até agora;
- O Problema da Intratabilidade: Explicação de por que a função de partição Z não pode ser calculada nos métodos clássicos de estimação;
- A proposta do centroide: Mostrar a necessidade de haver um modelo que trate também de relações entre centroides;
- Objetivo: Propor o modelo reparametrizado, descrever a inclusão de centroides e validar a inferência via Pseudoposteriori.

II. O Modelo Potts Reparametrizado

- Equação de Energia: Definição do modelo base com parâmetros α e β ;
- Adição de Efeitos de Centralidade: Introdução do parâmetro γ e a distância normalizada;
- Múltiplos Centroides: Regra do centroide mais próximo;
- Equilíbrio: Discussão sobre o limiar entre penalização global e efeito do centroide.

III. Métodos de Inferência

- Kmeans;
- Pseudoverossimilhança;
- (TALVEZ) Máxima Verossimilhança via Monte Carlo;;
- Metropolis-Hastings via Pseudoposteriori;

IV. (TALVEZ) Implementação Computacional

- Geração de Imagens: Regra de começar com uma imagem aleatória e ir usando o Gibbs Sampler;
- Performance: Truque de tirar o máximo do denominador no cálculo da log-verossimilhança e Repp;

V. Resultados e Discussão

- Experimentação: Cenários simulados com diferentes valores de atração/repulsão e localizações de centroides;
- Simulação e convergência: Gráficos de passeio aleatório, densidades, localização dos centroides e etc;
- Replicação: Comparação entre imagens geradas vs inferidas;
- Aplicação: Aplicação em dados reais.

VI. Conclusão

- Síntese: Reafirmar que a Pseudoposteriori realmente funciona bem para o problema;
- Vantagens do Modelo: Voltar aos pontos da introdução e aplicação.
- Próximos passos: Discutir possíveis propostas de melhorias ou novas aplicações para o modelo

2 13/07/26

2.1 Esqueleto do artigo

Título: Estimativa Bayesiana via Pseudoposteriori em Modelos de Potts com Efeitos de sementes.

I. Introdução

- Contextualização: Explicar o tipo de dado e como MRF é usado para a análise até agora;
- O Problema da Intratabilidade: Explicação de por que a função de partição Z não pode ser calculada nos métodos clássicos de estimação;
- A proposta do centroide: Mostrar a necessidade de haver um modelo que trate também de relações entre centroides;
- Objetivo: Propor o modelo reparametrizado, descrever a inclusão de centroides e validar a inferência via Pseudoposteriori.

II. O Modelo Potts Reparametrizado

- Equação de Energia: Definição do modelo base com parâmetros α e β ;
- Adição de Efeitos de Centralidade: Introdução do parâmetro γ e a distância normalizada;
- Múltiplos Centroides: Regra do centroide mais próximo;
- Equilíbrio: Discussão sobre o limiar entre penalização global e efeito do centroide.

III. Métodos de Inferência

- Kmeans: Introduzir o problema do chute inicial do centroide, a motivação da escolha do Kmeans e como é usado no processo de inferência;
- Pseudoverossimilhança: Explicar sobre o problema da intratabilidade do denominador, como isso é contornado pela pseudoverossimilhança e como se encaixa no algoritmo;
- Metropolis-Hastings via Pseudoposteriori: Mostrar toda a 'pipeline' e como ocorre a atualização em duas etapas, as prioris utilizadas e a regra de aceitação do passo;

IV. Resultados e Discussão

- Experimentação: Cenários simulados com diferentes valores de atração/repulsão e localizações de centroides;

- Simulação e convergência: Gráficos de passeio aleatório, densidades, localização dos centroides e etc;
- Replicação: Comparação entre imagens geradas vs inferidas.

V. Aplicação Prática

- Introdução: Destacar o problema a ser atacado e possíveis pré-tratamentos anteriores ao uso do modelo;
- Aplicação: Aplicação em dados reais.

VI. Conclusão

- Síntese: Reafirmar que a Pseudoposteriori realmente funciona bem para o problema;
- Vantagens do Modelo: Voltar aos pontos da introdução e aplicação.
- Próximos passos: Discutir possíveis propostas de melhorias ou novas aplicações para o modelo

2.2 Esboço Cap.2 - The Reparameterized Potts Model

Spatial data modeling on regular lattices often employs Markov Random Fields (MRF) to describe local dependencies. While the Ising model is restricted to binary states, the Potts model extends this framework to multiple categories. In this section, we propose a reparameterized version of the Potts model that incorporates global category abundance but also geographic centrality effects.

2.2.1 Energy Formulation and Gibbs Measure

Following the framework of Kindermann and Snell (1980), we consider a set of colors $S = 0, 1, \dots, r$ assigned to a regular grid T . To facilitate parameter estimation and interpretability, we utilize dummy variables $s_{i,k} \in \{0, 1\}$, where $s_{i,k} = 1$ if pixel i has color k and 0 otherwise.

The energy $U(\omega)$ of a given image configuration ω is defined as:

$$U(\omega) = -\alpha \sum_{\{i,j\} \in E} \sum_{k \in S} s_{i,k} s_{j,k} - \sum_{i \in T} \sum_{k \in S} \beta_k s_{i,k} \quad (1)$$

where α is the uniformity bias (negative values favor same-color neighbors) and β_k is the global penalty for color k . The probability is given by the Gibbs Measure $P(\omega) = \frac{1}{Z} e^{U(\omega)}$.

2.3 Incorporation of Geographic Centrality Effects

We introduce a parameter γ_k associated with the normalized Euclidean distance d_i between pixel i and a centroid c . Let $CB_{k,i}$ be the centrality bias for color k in the pixel i :

$$CB_{k,i} = \gamma_k \cdot d_i, \quad \text{with} \quad d_i = \frac{\sqrt{2}(\|i - c\| + 1)}{g} \quad (2)$$

where g is the grid side. Negative γ_k values penalize color energy far from the center (attraction), while positive values penalize it near the center (repulsion). The augmented energy is:

$$U(\omega) = -\alpha \sum_{\{i,j\} \in E} \sum_{k \in S} s_{i,k} s_{j,k} - \sum_{i \in T} \sum_{k \in S} (\beta_k + \gamma_k d_i) s_{i,k} \quad (3)$$

For identifiability, Color 0 is fixed as a reference ($\beta_0 = 0, \gamma_0 = 0$).

2.4 Extension to Multiple Centroids

To support m centroids, each pixel considers only its nearest neighbor: $d_i = \min(d_{i,1}, \dots, d_{i,m})$. This effectively partitions the space into regions of influence for each centroid.

2.5 Null Region and Influence Area

The null region for a color occurs when $\beta_k + \gamma_k d_i = 0$, so everything that happens in this region depends exclusively on α . This region leads us to the ratio $d_i = -\beta_k/\gamma_k$, also known as the influence area of a color-centroid.