

Estimação de Parâmetros em Campos Aleatórios de Markov Multi-Cores com Efeitos de Centralidade

Wesley Cabral Alves ¹
Victor Freguglia Souza ²

Resumo

Spatial data modeling on regular grids often employs Markov Random Fields (MRF) to describe local dependencies. This study proposes a reparameterized Potts model for multiple colors using dummy variables to capture spatial interaction (uniformity bias α) and category abundance (penalty β). Due to the computational challenge of the intractable normalizing constant Z , we explore three inference methods: Pseudolikelihood (PL), Monte Carlo Maximum Likelihood (MCML), and a Bayesian approach via Metropolis-Hastings using a Pseudoposterior. Furthermore, the model is extended to incorporate geographic centrality effects through a centroid parameter (γ), where the probability of a color depends on the Euclidean distance to the nearest centroid. Results from simulation using the Gibbs sampler demonstrate that the Pseudoposterior approach provides a robust and efficient framework for parameter estimation and uncertainty quantification in complex spatial settings, effectively balancing computational cost and statistical precision.

Palavras-chave: Centroides; campos aleatórios de Markov; pseudoposteriori; Metropolis-Hastings; verossimilhança intratável.

1 Introdução e Fundamentação Teórica

A modelagem de dados espaciais categorizados em reticulados regulares frequentemente recorre a técnicas baseadas em Campos Aleatórios de Markov para descrever dependências locais. Enquanto o modelo de Ising compreende estados binários e o modelo de Potts se estende a casos em que o número de estados possíveis é maior que 2, este estudo propõe um modelo de reparametrização para um conjunto de cores $S = \{0, 1, \dots, r\}$, conforme discutido em Kindermann and Snell (1980). Além disso, propõe formas de simular e estimar a adição de um centroide.

1.1 Formulação da Energia

Para o modelo base (sem centroide) a energia (U) de uma configuração de imagem ω é definida por:

$$U(\omega) = -\alpha \sum_{\{i,j\} \in E} \sum_{k \in S} s_{i,k} s_{j,k} - \sum_{i \in T} \sum_{k \in S} \beta_k s_{i,k} \quad (1)$$

Em que $\sum_{k \in S} s_{i,k} s_{j,k}$ pode ser interpretado como um delta de Kronecker para a combinação dos pixels vizinhos: 1 se i e j tem a mesma cor k do conjunto de cores S e 0 caso contrário. Este termo está contido em um somatório de (i, j) , pixels, em E que é o espaço de vizinhança que define a conectividade dos pixels da imagem. O parâmetro α define o

¹Departamento de Estatística, IMECC-Unicamp, Campinas - w225825@dac.unicamp.br

²Departamento de Estatística, IMECC-Unicamp, Campinas - victorfs@unicamp.br

viés de uniformidade: valores negativos de α tornam pixels vizinhos iguais mais prováveis e, portanto, regiões mais uniformes. Isoladamente, $s_{i,k}$ é uma variável indicadora que assume valor 1 se o pixel i tem a cor k . Já β_k é o parâmetro de penalização global da cor k : valores positivos fazem com que a cor esteja menos presente na imagem como um todo e sua combinação com $s_{i,k}$ percorre todo o espaço T (todos os pixels da imagem).

A Figura 1 apresenta uma simulação com valores de α e β_2 positivos, tornando maior a probabilidade de pixels vizinhos distintos e penalizando a cor amarela. O método de construção da imagem será descrito posteriormente.




Figura 1: Modelo Potts reparametrizado.

A probabilidade de uma configuração é dada pela Medida de Gibbs $P(\omega) = \frac{1}{Z}e^{U(\omega)}$, cuja constante de normalização ou função de partição é Z .

2 Métodos de Inferência

Inferir sob este modelo requer contornar alguns problemas: o primeiro deles é o fato de que a constante Z é considerada intratável para imagens reais, pois sua soma envolve calcular um número muito alto de configurações. Em uma imagem de 500x500 pixels com 3 cores, por exemplo, esse número seria $3^{250.000}$. O outro problema vem da natureza da Medida de Gibbs, que é o uso da função de energia como expoente na função, o que dificulta a convergência de métodos tradicionais como MCML.

Um ponto de atenção é que, por questões de identificabilidade do modelo, uma cor sempre é escolhida como referência e seus parâmetros β_k e γ_k não passam pelo processo de inferência. Nos exemplos mostrados neste estudo, a cor 0 é tida como a referência.

2.1 Pseudoverossimilhança (PL)

A pseudoverossimilhança de Besag (1975) contorna a intratabilidade global utilizando probabilidades condicionais locais. No modelo Potts reparametrizado, ela tem forma:

$$PL(\theta, \omega) = \prod_{i \in T} P(s_{i,k} = 1 | \omega_{N_i}) \quad (2)$$

$$P(s_{i,k} = 1 | \omega_{N_i}) = \frac{\exp\left(-\alpha \sum_{j \in N_i} s_{j,k} - \beta_k\right)}{\sum_{m \in S} \exp\left(-\alpha \sum_{j \in N_i} s_{j,m} - \beta_m\right)} \quad (3)$$

Em que k é a cor do pixel i na imagem e N_i é toda a vizinhança horizontal e vertical desse pixel, com θ representando o vetor de parâmetros.

Embora consistente, a pseudoverossimilhança (PL) fornece apenas estimativas pontuais e pode superestimar dependências em interações fortes. Além disso, em imagens maiores, pode tornar o processo de inferência muito lento, já que passa por todos os pixels da imagem.

2.2 Máxima Verossimilhança via Monte Carlo (MCML)

O método MCML de Geyer and Thompson (1992) estima a razão entre constantes de normalização $Z(\theta)/Z(\psi)$ através de amostragem por importância. A aproximação é dada por:

$$\frac{Z(\theta)}{Z(\psi)} \approx \frac{1}{n} \sum_{i=1}^n e^{U(\theta, \omega^{(i)}) - U(\psi, \omega^{(i)})} \quad (4)$$

Ao minimizar o logaritmo desta razão minimiza-se a logverossimilhança subtraída de $\log(Z(\psi))$, que é sempre positivo, e torna-se similar à otimização de $Z(\theta)$.

Este método encontra dificuldades à medida que o modelo fica mais complexo, principalmente após a adição do centroide. Por outro lado, não tem a mesma desvantagem que a pseudoverossimilhança tem em imagens grandes já que seu cálculo envolve estatísticas suficientes que podem ser extraídas uma única vez da imagem.

2.3 Metropolis-Hastings via Pseudoposteriori

Partindo para o processo de inferência através de uma abordagem bayesiana, busca-se a distribuição a posteriori $\pi(\theta|\omega)$. No entanto, como visto anteriormente, devido à intratabilidade da constante de normalização Z , a verossimilhança total não pode ser calculada diretamente.

Como alternativa, propõe-se o uso da pseudoposteriori, que substitui a verossimilhança global pela função de pseudoverossimilhança já discutida, combinando-a com uma distribuição a priori $p(\theta)$ (geralmente uma normal não informativa) para os parâmetros.

A pseudoposteriori alvo para o algoritmo é definida como:

$$\pi_{pseudo}(\theta|\omega) = PL(\theta) \cdot p(\theta). \quad (5)$$

Para amostrar dessa distribuição, utiliza-se o algoritmo de Metropolis-Hastings por meio de um passeio aleatório no espaço paramétrico.

3 Modelo com Adição de Centroides

A contribuição central deste trabalho é a inclusão de um efeito espacial geográfico no modelo de Potts tradicional. Introduce-se o parâmetro γ_k que, multiplicado pela distância euclidiana normalizada d_i entre o pixel i e o centroide mais próximo, altera a energia da cor. Para suportar um conjunto de c centroides, porém, cada pixel considera apenas o mais próximo, utilizando $d_i = \min(d_{i,1}, \dots, d_{i,c})$.

Desta forma, valores positivos de γ_k penalizam a cor em pixels afastados do centroide, enquanto valores negativos penalizam perto dele. A nova energia e suas probabilidades condicionais são descritas a seguir.

$$U(\omega) = -\alpha \sum_{\{i,j\} \in E} \sum_{k \in S} s_{i,k} s_{j,k} - \sum_{i \in T} \sum_{k \in S} (\beta_k + \gamma_k d_i) s_{i,k} \quad (6)$$

$$P(s_{i,k} = 1 | \omega_{N_i}) = \frac{\exp \left(-\alpha \sum_{j \in N_i} s_{j,k} - (\beta_k + \gamma_k d_i) \right)}{\sum_{m \in S} \exp \left(-\alpha \sum_{j \in N_i} s_{j,m} - (\beta_m + \gamma_m d_i) \right)} \quad (7)$$

A Figura 2 representa uma simulação com valor de α negativo, e valores de γ_2 e β_2 não nulos, com γ_2 positivo e relacionado a um centroide na coordenada (25,25).




Figura 2: Modelo com adição de centroide.

Com essa nova parametrização, um aspecto importante é a relação de forças entre β_k e γ_k , que representam separadamente a penalização global e a penalização centroidal, mas que, juntos, representam a área de influência do centroide.

Tomemos o ponto de equilíbrio entre os parâmetros para uma determinada cor k em um pixel i :

$$\begin{aligned} \beta_k + \gamma_k d_i &= 0 \\ d_i &= -\frac{\beta_k}{\gamma_k} \end{aligned} \quad (8)$$

Isso mostra que o limiar entre bônus e penalização da cor em relação à distância normalizada é essa razão. Por outro lado, o sinal do parâmetro γ implica se o caso é atrativo para o centroide ou repulsivo a ele.

Além disso, como a distância é sempre positiva, os parâmetros devem ter sinais diferentes para evitar a exclusão completa ou a adesão total à cor, assim como $|\beta_k| < |\gamma_k|$ mantém o limiar dentro da imagem.

4 Simulação

A geração da imagem é realizada através de um processo estocástico iterativo fundamentado no amostrador de Gibbs, iniciando-se com uma imagem com dimensões pré-definidas (nas figuras anteriores, 50x50) em que as cores são atribuídas de forma totalmente aleatória. A partir desse estado inicial, o algoritmo executa um número elevado de iterações (nos exemplos, 500.000) e em cada passo um pixel é selecionado aleatoriamente para ter sua cor reavaliada.

Para este pixel, calcula-se a energia associada a cada cor possível no espaço de cores S utilizando os parâmetros previamente escolhidos. Essas energias são transformadas em probabilidades locais por meio da Medida de Gibbs (utilizando a função exponencial normalizada), e a nova cor do pixel é sorteada de acordo com essa distribuição de probabilidades, o que faz com que a imagem respeite os parâmetros utilizados, mas ainda possa comportar pequenas exceções.

Para ilustrar o poder de inferência dos métodos citados acima, a Tabela 1 apresenta os valores reais dos parâmetros que geraram a Figura 2, bem como os valores obtidos por meio da pseudoverossimilhança, que foram usados para construir a distribuição à pseudoposteriori via Metropolis-Hastings, cuja média também é mostrada.

Tabela 1: Parâmetros reais e estimados.

Parâmetro	Real	PL ¹	MH ²
Alpha	-1.200	-1.243	-1.236
Beta Ref	0.000	-	-
Beta 1	0.000	0.588	0.292
Beta 2	-1.200	-0.717	-1.039
Gamma Ref	0.000	-	-
Gamma 1	0.000	-0.903	-0.347
Gamma 2	3.000	1.994	2.792

¹ PL: estimativas via pseudoverossimilhança.

² MH: média à pseudoposteriori via Metropolis-Hastings

A Figura 3 mostra, à esquerda, as distribuições dos parâmetros com linhas pontilhadas em azul marcando os quantis de 5% e 95%, enquanto a linha vermelha representa o valor utilizado na geração da imagem. Em todos os casos o valor real esteve contido no intervalo interquantil. À direita, o passeio aleatório (que começa nas estimativas via PL) mostra que após 10.000 passos todos os parâmetros parecem convergir ao valor verdadeiro.




Figura 3: Distribuição à pseudoposteriori e passeio aleatório.

5 Conclusão

A evolução de modelos de Ising binários para modelos multi-cores espaciais com efeitos de centralidade é viabilizada por aproximações locais e estocásticas. Conclui-se que a pseudoposteriori é o método mais eficiente para equilibrar custo computacional e precisão estatística em problemas de verossimilhança intratável deste tipo.

Referências

- Besag, J. (1975). Statistical analysis of non-lattice data. *The Statistician* 24(3), 179–195.
- Geyer, C. J. and E. A. Thompson (1992). Constrained monte carlo maximum likelihood for dependent data. *Journal of the Royal Statistical Society. Series B (Methodological)* 54(3), 657–699.
- Kindermann, R. and J. L. Snell (1980). *Markov Random Fields and Their Applications*, Volume 1. Providence, Rhode Island: American Mathematical Society.